

ФГАОУ ВО «НИУ ИТМО»
ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ
И КОМПЬЮТЕРНОЙ ТЕХНИКИ

Лабораторная работа №1

(по дисциплине «Системы искусственного интеллекта»)

Выполнил:

Лабин Макар Андреевич,
СИИ 2.1, Р3331, 466449.

Проверил:

Запорожцев Иван Федорович,
кандидат технических наук

ИТМО

г. Санкт-Петербург, Россия
2026

Содержание

1	Задание	1
2	Выполнение работы	3
2.1	Описание задачи	3
2.1.1	Выбор датасета	3
2.1.2	EDA	3
2.1.3	Формулировка задачи	3
2.2	Обучение моделей	3
2.3	Ответы на вопросы	3
2.4	Математическое обоснование MSE	3

1 Задание

Task 1: [4 балла]

Выберите датасет и задачу для него (регрессия) — с Kaggle или [UCI Machine Learning Repository](#).

Рекомендации:

- количество признаков — не менее 10
- количество объектов — не менее 100
- возраст датасета — не старше 2010 года

Выполните EDA, а именно: придумайте вопросы к данным, которые потребуют использования следующих инструментов (напишите каждый вопрос и код к нему) [0,5 балла за покрытие каждого пункта]:

- группировка с агрегацией (groupby) (минимум два признака задействовано в пункте);
- изменение дискретности по времени (resample) (можно для этого пункта искусственно добавить время (поминутно → в час));
- объединение датафреймов (merge, join или concat) (можно искусственно разбить датафрейм на два: мальчики/девочки разбили по полу, потом собрали к исходному или другому);
- статическая визуализация seaborn;
- интерактивный график plotly;
- визуализация распределений (гистограмма относительных частот, kde, boxplot, violinplot, scatter);
- тесты на свойства распределения (например, нормальность);
- One Hot Encoding для категориальных признаков (если их нет, то придумайте как некие классы, определяемые по другим числовым признакам).

Task 2: [4 балла]

1. Выберите один из признаков как таргет (регрессант, предиктант), также выберите некоторое число признаков в качестве регрессоров (предикторов). Обоснуйте, что эти признаки имеют смысл использовать как регрессоры, исходя из предметной области (природы датасета), проведите аналитику — представьте код и рисунки. [1 балл]

Важно! Если выполняете исследование данных до разделения на обучающую, которая нужна для моделирования, и отложенную выборку (тестовую), то это потенциал для утечек (data leakage)! Следует сразу отделить часть данных, исследовать их только перед прогоном на уже обученной готовой модели!

2. Обучите линейную регрессионную модель без регуляризации. Проиллюстрируйте процесс обучения и тестирования модели, запишите выводы о качестве. Метрики: RMSE, MAE, R^2 [1 балл]

3. Обучите линейную регрессионную модель с регуляризацией (любой). Для предобработки осуществите удаление выбросов и нормирование - запишите обоснование для выбора способа поиска выбросов и нормирования. Используйте для этапов Pipeline из sklearn. Проиллюстрируйте процесс обучения и тестирования модели, запишите выводы о качестве. Метрики: RMSE, MAE, R^2 [2 балла]

Task 3: [2 балла — бонус]

По итогам лекции №1 ответьте на вопросы о месте искусственного интеллекта среди инноваций в крупной компании (пример «Норильского никеля» — см. видео в группе Telegram):

1. Какие задачи моделирования и управления решаются?
2. Какие разделы/формальные задачи ИИ задействованы?
3. Какие физико-химические признаки для них используются?
4. Укажите (предположите) для нескольких признаков: числовые или категориальные, временная и пространственная дискретность регистрации, сырой признак или агрегат по нескольким, сильно зашумленный, много ли пропусков, особенности закона распределения, потенциал для data leakage.

Task 4: [3 балла — бонус]

Покажите, что из максимизации правдоподобия выборки невязок, распределенных по нормальному закону, следует задача минимизации ошибки MSE, вычисленной по этим невязкам.

Обоснование принесет вам 2 балла.

Если выполните не на листе бумаги, а заполните ячейку (математические символы), то получите ещё 1 балл.

2 Выполнение работы

2.1 Описание задачи

2.1.1 Выбор датасета

Для рассмотрения задачи регрессии был выбран датасет [Student Performance](#) с репозитория UCI Machine Learning. Он имеет следующие характеристики:

- количество признаков — 30;
- количество объектов — 649;
- год публикации — 2014.

В датасете представлены результаты студентов среднего образования двух португальских школ. Данные включают оценки студентов, демографические, социальные и школьные характеристики, и были собраны с использованием школьных отчётов и анкет.

Предоставлены два набора данных, касающиеся успеваемости по двум различным предметам: Математика и Португальский язык.

Важное замечание от авторов: целевой признак G3 имеет сильную корреляцию с признаками G2 и G1. Это происходит потому, что G3 является итоговой оценкой за год (выданной в 3-м периоде), в то время как G1 и G2 соответствуют оценкам за 1-й и 2-й периоды.

2.1.2 EDA

Идеи:

- groupby по medu и sex
- merge / join по school
- resample по age (добавим искусственно дату рождения -> возраст)
- ...
- one hot encoding по reason

2.1.3 Формулировка задачи

Регрессировать Total Alcohol Consumption вместо G3

2.2 Обучение моделей

...

2.3 Ответы на вопросы

...

2.4 Математическое обоснование MSE

...