ФГАОУ ВО «НИУ ИТМО»
Факультет программной инженерии
и компьютерной техники

Лабораторная работа №3

Задача классификации

(по дисциплине «Системы искусственного интеллекта»)

Выполнил:

Лабин Макар Андреевич,
СИИ 2.1, P3331, 466449.

Проверил:

Запорожцев Иван Федорович,
кандидат технических наук

г. Санкт-Петербург, Россия
2026

Содержание

1 Задание **1**

2 Выполнение работы **3**
2.1 Обучение моделей 3
2.1.1 Выбор датасета 3
2.1.2 Формулировка задачи 3
2.1.3 Обучение LogisticRegression 4
2.1.4 Обучение SVM 4
2.2 Метрики многоклассовой классификации 4
2.2.1 AUC ROC 4
2.2.2 PR-кривая 4
2.2.3 Выводы 4
2.3 Применение OneClassSVM 4

3 Источники литературы **5**

1 Задание

Task 1: *[2 балла]*

Выберите датасет и задачу для него (классификация) — с Kaggle или UCI Machine Learning Repository.

Рекомендации:

- количество признаков — не менее 10;
- количество объектов — не менее 100;
- возраст датасета — не старее 2010 года;
- пользуйтесь датасетом из предыдущих лабораторных работ, если он подходит под условия выше.

Затем выполните следующие действия:

- Выберите (или сгенерируйте сами) признак, который будет целевым для бинарной классификации.
- Используйте LogisticRegression из sklearn. Задайте несколько параметров метода самостоятельно, поясните их назначение и причину выбора конкретных значений.
- Используйте несколько метрик, чтоб оценить результаты бинарной классификации (метрики, доступные в sklearn).

Task 2: *[2 балла]*

Выполните бинарную классификацию аналогично предыдущему пункту с использованием SVM из sklearn. Используйте `kernel='linear'`, сами подберите параметр регуляризации C и ответьте на вопрос:

- Может ли SVM учесть несбалансированность классов? Если да, то как? Если нет, то почему?

Task 3: *[6 баллов]*

(a) Многоклассовая классификация.[2 балла]

- Дайте определения для подходов: микро, макро, взвешенный, пообъктный.
- Выполните расчёты вручную для слайда 43 (на примере любых 3 промежуточных AUC ROC, поясните, как из промежуточных характеристик получаются 4 финальных).
- В рамках детализации **оцифруйте** ROC: в Excel, отрисуйте линиями в Word или отрисуйте отдельными отрезками Python-кодом (не используйте готовые функции для ROC).

(b) Для одного из кейсов (одного класса):[2 балла]

- Введите три порога бинаризации так, чтоб получились различные Accuracy, Recall, Precision.

- Вычислите эти метрики вручную и сопроводите визуализацией расчёта для Recall и Precision (см. пример из лекции с окружностями разных цветов и радиусов).
- По трём парам (Precision, Recall) постройте эскиз PR-кривой.

(c) Сделайте выводы по результатам расчётом AUC ROC для многоклассовой классификации:[1 балл]

- какой вариант лучше и почему;
- объясниь падение AUC ROC при переходе к многоклассовым.

(d) В каких кейсах/доменах следует применять те или иные варианты? Запишите выводы. [1 балл]

Task 4: *[2 балла]*

Исследуйте вопрос выбросов/новизны для данных в вашем датасете с использованием OneClassSVM. Дайте краткую теоретическую характеристику, используйте готовые решения для получения результатов, сделайте выводы.

Материалы для изучения указаны в списке литературы.[1; 2]

2 Выполнение работы

2.1 Обучение моделей

2.1.1 Выбор датасета

Для рассмотрения задачи регрессии был выбран датасет Student Performance с репозитория UCI Machine Learning.[3] Он имеет следующие особенности:

- количество признаков — 30;
- количество объектов — 649;
- год публикации — 2014;
- использовался в предыдущей лабораторной работе.[4]

В датасете представлены результаты студентов среднего образования двух португальских школ. Данные включают оценки студентов, демографические, социальные и школьные характеристики, и были собраны с использованием школьных отчётов и анкет.

Предоставлены два набора данных, касающиеся успеваемости по двум различным предметам: Математика и Португальский язык.

2.1.2 Формулировка задачи

В качестве целевой переменной *(метки класса)* предлагается использовать желание получить высшее образование (`higher`).

В качестве фичей *(предикторов)* возьмём следующие признаки из датасета:

- `age` (возраст) — числовой признак, который может коррелировать с желанием получить высшее образование;
- `Medu` (образование матери) — числовой признак, который может коррелировать с желанием получить высшее образование, так как более высокий уровень образования родителей может способствовать академическим амбициям студентов;
- `Fedu` (образование отца) — числовой признак, аналогично `Medu`;
- `absences` (количество пропусков) — числовой признак, который может отражать уровень ответственности и дисциплины студентов;
- `failures` (количество академических неудач) — числовой признак, который может быть связан с поведением студентов и их отношением к учебе;
- `G3` (итоговая оценка) — числовой признак, который может быть индикатором академической успеваемости и мотивации студентов;
- `famsup` (поддержка семьи) — категориальный признак, который может влиять на желание студентов продолжать образование;

- `schoolsup` (поддержка школы) — категориальный признак, который может отражать доступность ресурсов и поддержки для студентов;
- `studytime` (время, затраченное на учебу) — числовой признак, который может быть связан с академической мотивацией.

2.1.3 Обучение LogisticRegression

...

2.1.4 Обучение SVM

...

2.2 Метрики многоклассовой классификации

2.2.1 AUC ROC

...

2.2.2 PR-кривая

...

2.2.3 Выводы

...

2.3 Применение OneClassSVM

...

3 Источники литературы

1. *scikit-learn developers.* Outlier detection / scikit-learn. — URL: https://scikit-learn.ru/stable/modules/outlier_detection.html (дата обр. 10.10.2026) ; Неофициальный перевод сайта scikit-learn.org.
2. *Дьяконов А.* Поиск аномалий / WordPress. — URL: https://alexanderdyakonov.wordpress.com/ (дата обр. 10.10.2026) ; Блог.
3. *Cortez P.* Student Performance Dataset / UCI Machine Learning Repository. — 2014. — URL: https://archive.ics.uci.edu/dataset/320/student+performance (дата обр. 24.09.2026).
4. *Лабин М. А.* Лабораторная работа №1: Pandas, EDA, линейная регрессия. — Санкт-Петербург, 2026. — Отчет по дисциплине «Системы искусственного интеллекта».