ФГАОУ ВО «НИУ ИТМО»
Факультет программной инженерии
и компьютерной техники

Лабораторная работа №4

Decision Tree

(по дисциплине «Системы искусственного интеллекта»)

Выполнил:

Лабин Макар Андреевич,
СИИ 2.1, P3331, 466449.

Проверил:

Запорожцев Иван Федорович,
кандидат технических наук.

г. Санкт-Петербург, Россия
2026

Содержание

1 Задание **1**

2 Выполнение работы **4**

3 Источники литературы **5**

1 Задание

Мы будем работать с данными из датасета[1], в котором содержится информация об объектах недвижимости в России с их стоимостью за 2018–2021 гг.

- Цена — цена в рублях РФ (*числовое*);
- Дата — дата публикации объявления (*временное*);
- Время — время публикации объявления (*временное*);
- Координата x — значение координаты (широта) (*числовое*);
- Координата y — значение координаты (долгота) (*числовое*);
- Номер — код региона РФ (*категориальное*);
- Тип здания — тип сооружения, в котором находится квартира (*категориальное*);
- Этаж — номер этажа, на котором находится квартира (*категориальное* или *числовое*?);
- Число этажей в доме — общее количество этажей в здании (*категориальное* или *числовое*?);
- Комнаты — количество комнат в квартире, -1 означает студии с открытой планировкой (*категориальное* или *числовое*?);
- Площадь — общая площадь квартиры в кв. метрах (*числовое*);
- Площадь кухни — площадь кухни в кв. метрах (*числовое*);
- Тип квартиры — тип квартиры, где 1 означает вторичный рынок недвижимости, 11 — новостройка (*категориальное*).

Целевой переменной будем считать цену (столбец `price`).

Task 1: *[1 балл]*

Сделайте первичную обработку данных.

1) Выберите один любой регион/город, для которого достаточно данных для построения модели, и оставьте выборку только для этого региона/города. Напишите, какой город выбрали.
2) Удалите некорректные записи и выбросы.
3) Создайте дополнительную колонку `year` — год продажи.
4) Удалите колонки `date` и `time`.
5) Исключите 1% с каждого хвоста распределения по целевой переменной.
6) Исключите 1% с каждого хвоста распределения по тем переменным, по которым Вам кажется важно это сделать.

7) Исследуйте, какие ещё признаки можно преобразовать различными способами, например, нелинейная трансформация и пр. Выберите такие признаки и преобразуйте их.

Выведите на экран первые строки изменённой таблицы, чтобы проверить, что все преобразования сработали.

Исследуйте закон распределения целевого признака. Является ли распределение нормальным?

Task 2: *[1 балл]*

Подготовка к обучению.

1) Создайте матрицу объект-признак `X` и вектор с целевой переменной `y`.
2) Разбейте данные на тренировочную и тестовую части, размер тестовой части — 30%.
3) Для линейных моделей важно применить нормализацию, возьмём `StandardScaler`, обучим метод на тренировочных данных и применим его и к трейну, и к тесту.
4) После масштабирования признаков `X_train` и `X_test` перестали быть объектами типа `pd.DataFrame`, это неудобно. Приведите их снова к `pd.DataFrame`.

Task 3: *[1 балл]*

Обучите на тренировочных данных с параметрами по умолчанию:

1) линейную регрессию `Ridge`;
2) метод опорных векторов `SVR` (с `kernel='linear'`).

Важно! `SVR` может долго обучаться без нормализации данных, возьмите на заметку.

С помощью обученных моделей сделайте предсказание на тестовых данных. Вычислите значение метрики `RMSE` на тесте.

Task 4: *[2 балла]*

Обучите `DecisionTreeRegressor` с параметрами по умолчанию на тренировочных данных, сделайте предсказание на тесте и вычислите на тесте `RMSE`.

Нужно ли масштабировать признаки для обучения решающего дерева? Проверьте это, заново разбив данные на тренировочную и тестовую части, назовите новые полученные объекты новыми названиями и проведите обучение, предсказание и оценку метрики до масштабирования и после.

Подсказка: можно использовать любой метод масштабирования признаков.

Какой вывод про масштабирование признаков для обучения дерева можно сделать?

Task 5: *[3 балла]*

Теперь ваша цель — максимально улучшить модели. Для этого:

1) у линейных моделей:
   - `SVR` (если смогли обучить модель) — подберите гиперпараметр C (переберите 20 значений C в диапазоне от 0.1 до 10 с равным шагом);
   - `Ridge` — подберите гиперпараметр α (переберите 20 значений α в диапазоне от 10^{-3} до 10^3 с равным логарифмическим шагом).
2) у решающего дерева подберите `max_depth` (переберите глубину от 1 до 10 с шагом 1) и `criterion` — `squared_error` или `absolute_error`.

Для подбора параметров используйте `GridSearchCV` с 5 фолдами и метрикой `r2`.

Важно! Подбор параметров осуществляется только по тренировочным данным! Контролируйте свои пайплайны обучения на предмет ликов!

После подбора гиперпараметров обучите модели с найденными гиперпараметрами на тренировочных данных, сделайте предсказания на тесте и оцените их качество (`RMSE`).

Какая модель справилась с решением задачи лучше всего по метрике `RMSE`?

Подсказка: оформите полученные метрики в `pd.DataFrame`.

Task 6: *[1 балл]*

Постройте диаграммы (горизонтальные бары) важности признаков для линейной регрессии и дерева (для линейных моделей берите модуль значений весов). Сравните между собой списки из трёх самых важных признаков. Совпадают ли они?

Task 7: *[1 балл]*

Сделайте выводы по самой лучшей модели:

1) Какая модель после подбора гиперпараметров лучше всего решает задачу с точки зрения метрики `RMSE`?
2) Достаточное ли качество получившейся модели? Можно ли её использовать в проде?
3) Как можно ещё улучшить получившуюся модель? Как в случае линейной модели, так и для дерева.

2 Выполнение работы

...

3 Источники литературы

1. *Daniilak*. Russia Real Estate 2018–2021 / Kaggle. — URL: https://www.kaggle.com/datasets/mrdaniilak/russia-real-estate-20182021 (дата обр. 14.11.2026) ; Dataset.